# Trabalho Final - Aluno: Vitor Duarte Bezerra de Oliveira

- 1. Ferramenta para o ETL e dashboard = PowerBI.
- 2. Tema escolhido = Simulação do setor de análise de desempenho em uma equipe de futebol (Equipe escolhida = Real Madrid da Espanha)
- 3. Perguntas Analíticas:

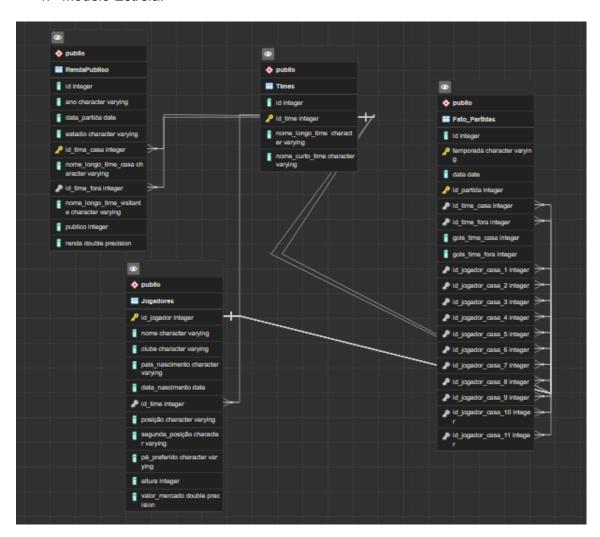
Quantos gols foram marcados fora de casa e dentro de casa na temporada?

Maior público necessariamente vai significar mais renda?

Jogadores mais velhos estão com um valor de mercado maior que nossos jogadores mais jovens?

Qual a distribuição no mapa do local em que nossos jogadores nasceram e seu valor de mercado?

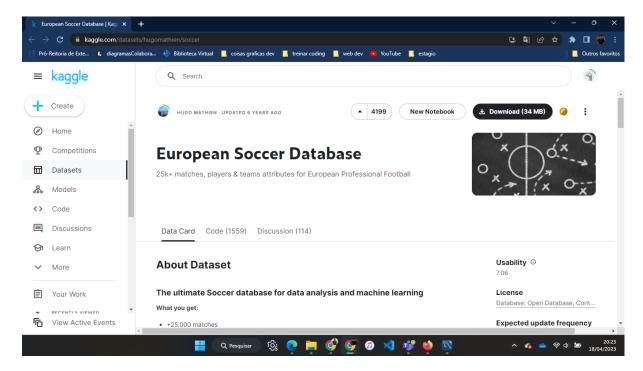
#### 4. Modelo Estrela:



- 5. Obtenção das fontes de dados:
  - Arquivo Sqlite (tabela relacional):

Tabela contendo todos os dados das partidas (tabela fato)

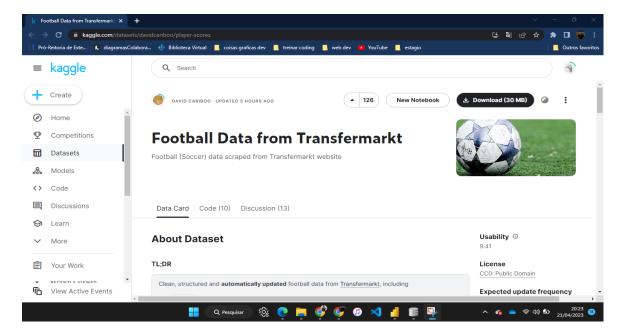
https://www.kaggle.com/datasets/hugomathien/soccer



• Arquivo Csv:

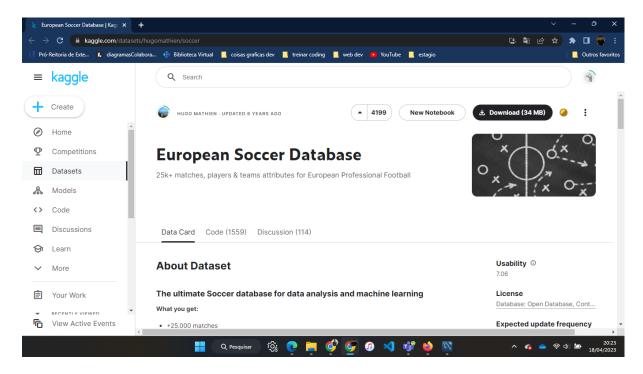
(https://www.kaggle.com/datasets/davidcariboo/player-scores)

quando baixa vem mais de um csv, escolhi somente o de jogadores (contendo dados de todos os jogadores) ⇒ montar a nossa equipe



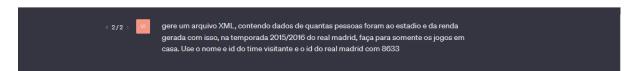
#### Arquivo Json:

Foi pegado da mesma Database de onde tirei a tabela relacional, porém, é outra tabela diferente contendo informações sobre todos os times. Essa tabela foi transformada para Json (vai ser útil para saber com quem o real madrid jogou)



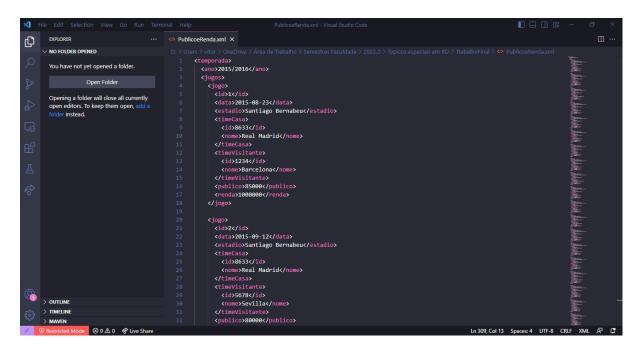
# arquivo XML:

Gerado pelo chat gpt contendo informações sobre público no estádio e renda nos jogos em casa (gerou para 19 jogos, mesma quantidade de jogos em casa da tabela fato Partidas)



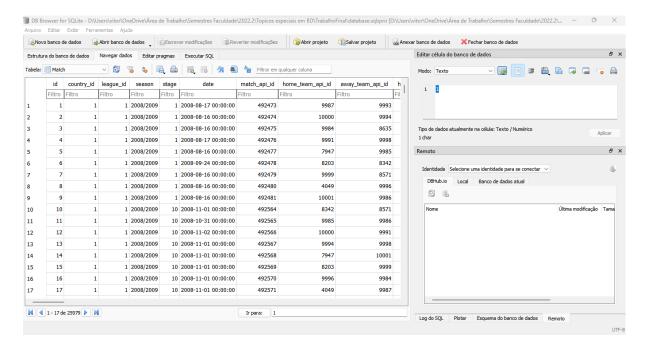
arquivo XML gerado, foi necessário alterar o id do time visitante para o que temos no Json de time

(foi salvo em um arquivo .xml,para ser importado ao power BI), arquivo final com 310 linhas



## 6. Partindo para o processo de ETL:

• Tabela sql das partidas ⇒ assim que ela veio = tabela fato do modelo estrela



## importada para o powerBI

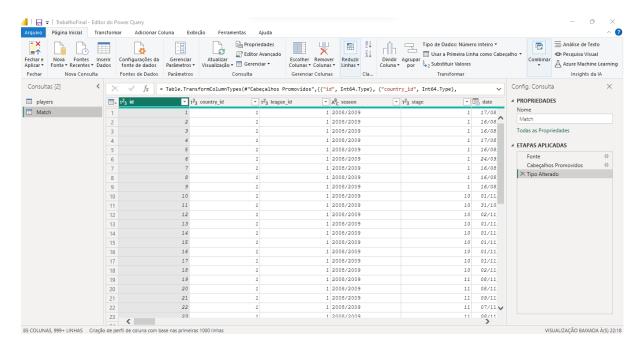
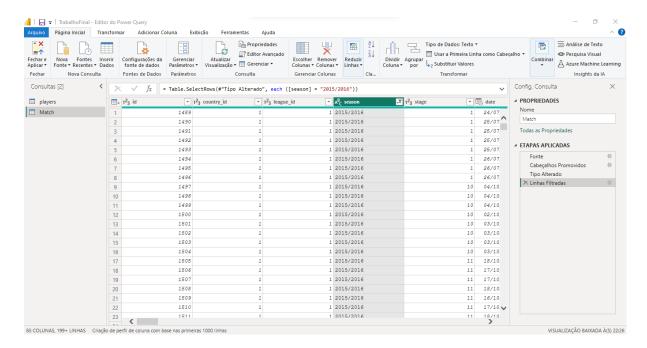


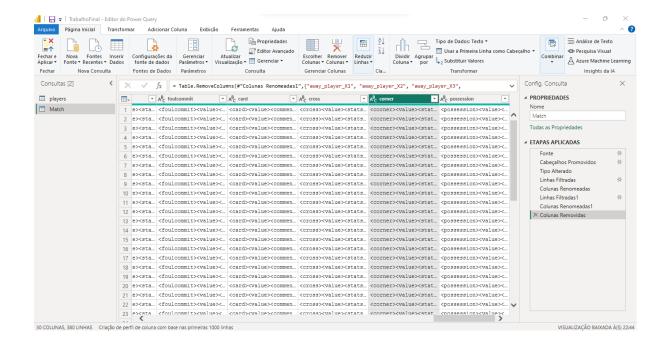
Tabela enorme com mais de 30.000 linhas contendo partidas desde 2008 até 2016 ⇒ primeiramente selecionei apenas as linhas com as partidas mais atuais (deixei só 2015 e 2016)



após selecionei apenas o país que nos interessa (pais do Real madrid = Espanha = country\_id = 21518)

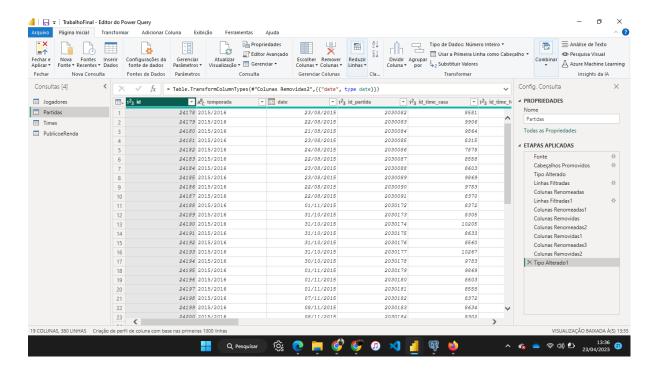
já diminuímos para 380 partidas (380 linhas na tabela) ⇒ ficamos apenas com os jogos acontecidos na espanha,

essas colunas vieram bugadas da tabelas (foram removidas)



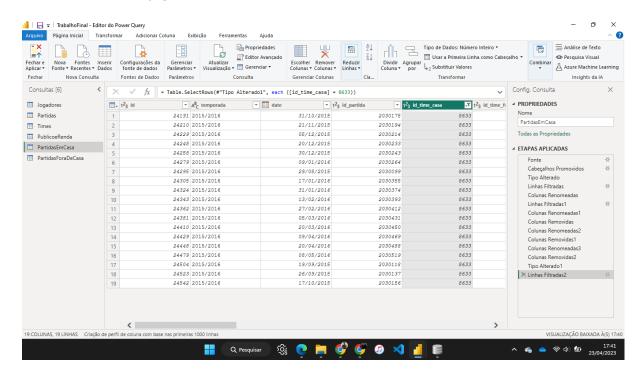
- Colunas desnecessárias e bugadas foram removidas
  - 1.1. id dos 11 jogadores adversários
  - 1.2. gols
  - 1.3. chutes dados e recebidos
  - 1.4. faltas
  - 1.5. cartões
  - 1.6. cruzamentos
  - 1.7. escanteios
  - 1.8. stage
  - 1.9. posse de bola
  - 1.10. id\_pais
  - 1.11. id\_liga

## Nome das colunas foram traduzidas

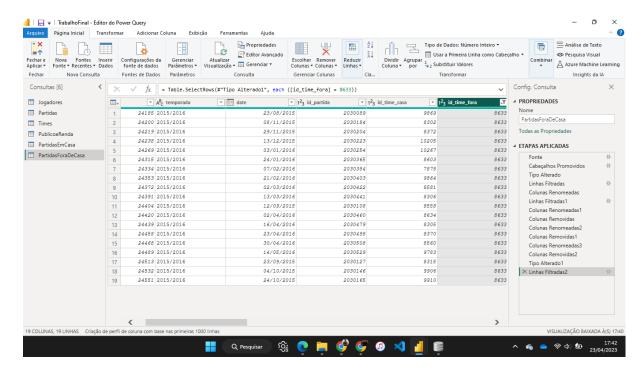


Dessa tabela gerei duas outras, para visualizar melhor as partidas foram e dentro de casa

tabela apenas para jogos dentro de casa:

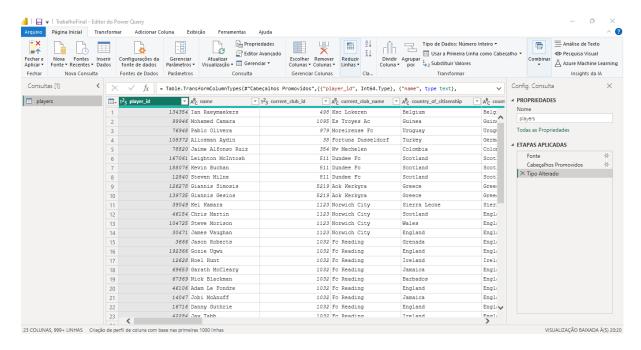


# tabela para jogos fora de casa



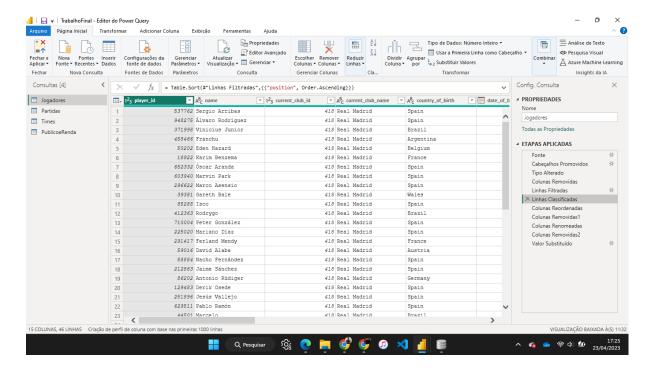
podemos ver que a visualização dos jogos fora e dentro de casa fica bem mais fácil

• Csv somente com dados dos jogadores - tabela jogadores

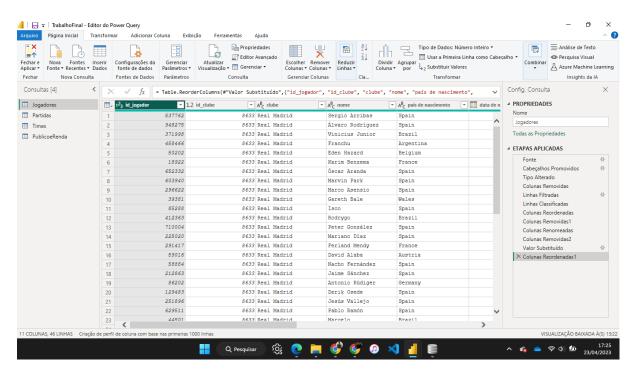


- 2. Colunas desnecessárias e bugadas foram removidas
  - 2.1. url da imagem e da logo do time
  - 2.2. primeiro nome
  - 2.3. ultimo nome
  - 2.4. apelido do jogador
  - 2.5. código do país
  - 2.6. nome do agente
  - 2.7. data de expiração de contrato
  - 2.8. país de cidadania
  - 2.9. cidade de nascimento
  - 2.10. última temporada
  - 2.11. valor de mercado mais alto

Após todas as remoções foi realizado um filtro para termos apenas os jogadores do Real Madrid



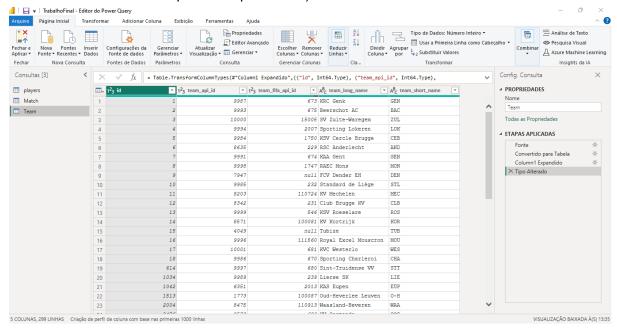
nome das colunas foram traduzidos e id do clube foi alterado para bater como o id do real madrid na tabela fato partidas (foi de 418 para 8633)



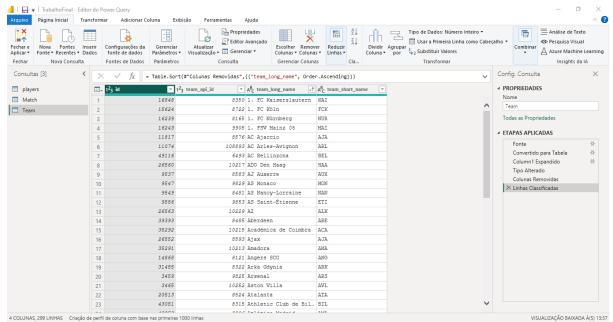
dados do csv foram importados e salvos no PowerBI

## Arquivo Json

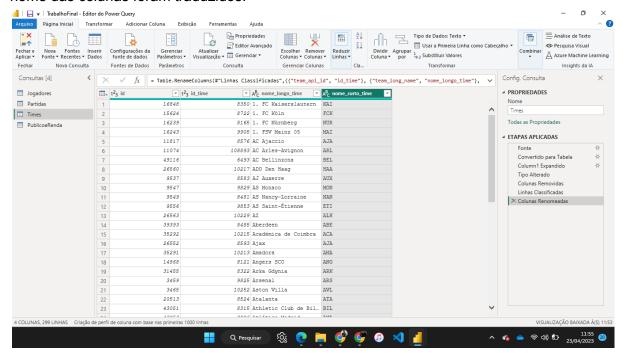
(como já explicado anteriormente, foi pegado uma tabela diferente, tabela com informações dos times e transformada para o arquivo Json)



# foi removida a coluna do team\_fifa\_api\_id

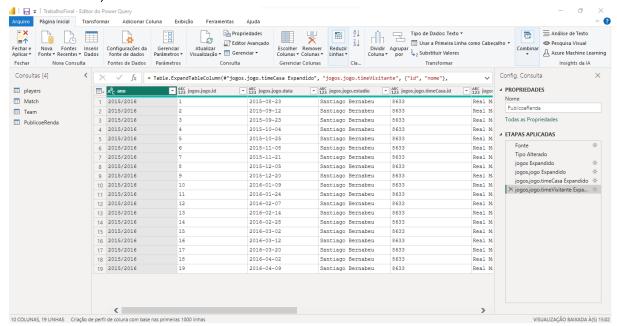


#### nome das colunas foram traduzidos:

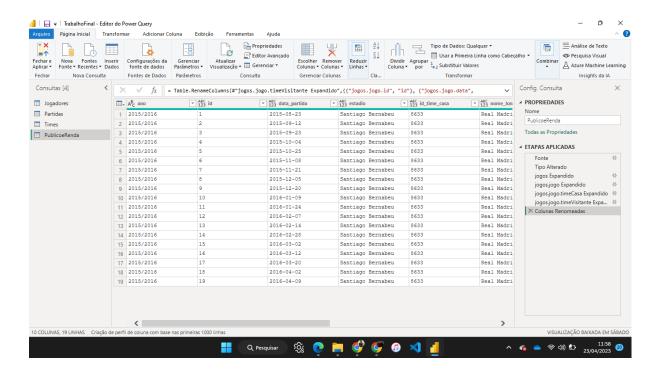


## json foi importado e salvo no PowerBI

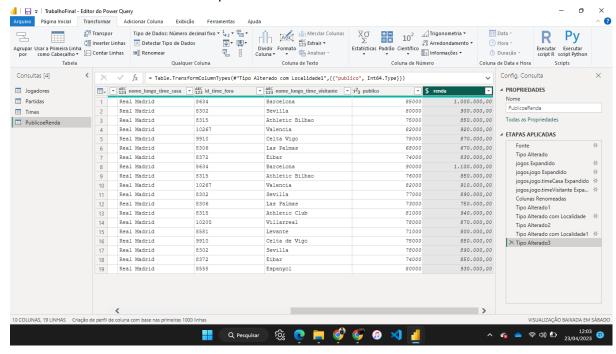
 Arquivo XML (arquivo contendo renda e público nos 19 jogos em casa do real madrid)



#### colunas foram renomeadas:



#### valores de renda foram filtrados para euro



xml importado para powerBl

# 10. Dashboard que responda às perguntas:

(disponível para acesso no site: <a href="https://trabalho-engenharia-de-dados.vercel.app/">https://trabalho-engenharia-de-dados.vercel.app/</a>)

## Relembrando as perguntas:

Quantos gols foram marcados fora de casa e dentro de casa na temporada?

Maior público necessariamente vai significar maior renda?

Jogadores mais velhos estão com um valor de mercado maior que nossos jogadores mais jovens?

Qual a distribuição no mapa do local em que nossos jogadores nasceram e seu valor de mercado?

